

大模型后训练与强化学习中的低比特量化：NVFP4、MXFP8 与 MXFP4

执行摘要

本报告以 2025 年 8 月 2 日至 2026 年 8 月 2 日为主要检索窗口，重点分析低比特浮点格式在大模型监督微调、偏好对齐、可验证奖励强化学习和 RLHF 中的应用。

核心判断如下。

第一，**QeRL** 是目前“低比特量化直接改善强化学习效果”这一方向的代表性工作。它不是简单地把 QLoRA 用于 RL，而是将冻结的 NVFP4 基座、BF16 LoRA、GRPO/DAPO 和 Adaptive Quantization Noise (AQN) 组合起来：量化一方面降低 rollout 的权重带宽和显存，另一方面通过适度扰动 logits、提高策略熵来增强探索。Qwen2.5-7B 在 GSM8K 上达到 90.8%，接近 BF16 全参数训练的 91.2%；论文还报告相对 BF16 LoRA 约 1.2–1.5 倍的 rollout 吞吐提升，并演示了单张 H100 80GB 容纳 32B RL 的可行性。需要强调的是，QeRL 在 H100 上使用的主要是 **NVFP4 权重量化加 BF16 激活的 W4A16/Marlin 路径**，并非 Blackwell 上原生的端到端 NVFP4 W4A4 训练。¹

第二，近一年的研究已经从“量化后精度是否下降”转向“**训练端与 rollout 端的量化误差是否一致**”。QaRL、QuRL、QUADS 和 HiFloat4 的共同结论是：最危险的配置通常不是低比特训练本身，而是 **BF16 trainer 与低比特 rollout actor 之间的策略分布错配**。权重误差、激活离群值、路由器漂移和微小 RL 更新被量化网格吞没，都会使 importance ratio 和优势估计失真，严重时导致策略坍缩。解决方法包括 rollout-aligned QAT、非对称 W4A16 trainer、残差激活补偿、动态 clipping、更新尺度放大以及量化感知噪声调度。²

第三，从工程成熟度看，**MXFP8 是当前最低风险的低精度训练选项**，NVFP4 是 NVIDIA Blackwell 上最高压缩率但工程要求最高的选项，MXFP4 是跨 NVIDIA/AMD 平台最有吸引力、但对激活离群值最敏感的 4-bit 选项。MXFP8 使用 32 元素块和 E8M0 幂次尺度，已有 1856 张 B200 上 1.22–1.28 倍训练加速并保持近似 BF16 收敛的公开实践。NVFP4 使用 16 元素局部 E4M3 尺度和额外 FP32 全局尺度，通常比 MXFP4 有更好的 FP4 数值保真度，但要求全局尺度同步、权重重排和更复杂的 rowwise/columnwise 布局。MXFP4 使用开放 OCP MX 规范，能够跨 Blackwell 和 AMD MI350/MI355 部署，但 naïve W4A4 对小模型、激活离群值和 RL rollout 尤其敏感。³

第四，面向实际项目，建议采用逐级降精度策略，而不是直接从 BF16 跳到端到端 FP4：

硬件与目标	建议首选	下一步优化	不建议直接采用
A100/H100，7B–70B 后训练	BF16/FP8 rollout 基线；NVFP4A16 或 MXFP4A16 冻结基座加 LoRA	QeRL 式 AQN；量化 actor 与 BF16 shadow actor 对齐监控	假设 H100 能原生获得 NVFP4 W4A4 Tensor Core 加速
B200/GB200，低风险训练	MXFP8 trainer 与 rollout	NVFP4 W4A4 rollout；再加入 QAT/残差补偿	BF16 trainer 加 naïve NVFP4 rollout


硬件与目标	建议首选	下一步优化	不建议直接采用
B200/ GB200, 极限 显存与吞吐	NVFP4 W4A4, 保留敏感 层 BF16/MXFP8	QUADS/QaRL 式双端误差对齐	一次性量化全部权重、 激活、KV 和路由器
AMD MI350/ MI355	MXFP8 或 MXFP4/MXFP6 混合精度	Quark、AutoSmoothQuant、 GPTQ、局部高精度回退	依赖 NVIDIA 专有 NVFP4 checkpoint
首次 RLHF/ RLVR 验证	LoRA/QLoRA + BF16/FP8 rollout	先做 W4A16, 再尝试 W4A4	在奖励、KL、熵监控 尚不完善时直接全低比 特

QeRL 论文详解

论文信息。《QeRL: Beyond Efficiency — Quantization-enhanced Reinforcement Learning for LLMs》，arXiv:2510.11696, 2025 年 10 月发布, 作者提供了 NVIDIA Research 官方实现 [NVlabs/QeRL](#)。论文的核心命题是：量化在 RL 中不仅是节省显存和提高吞吐的压缩手段，还可能作为一种结构化策略扰动，提高策略熵和探索效率。 4

研究问题。传统 QLoRA 主要面向监督微调，其 NF4 权重需要反量化或依赖查表/解包内核；在 rollout 占主导的 LLM 强化学习中，QLoRA 未必比 BF16 LoRA 更快。同时，数学推理 RL 常出现探索不足、策略熵过早下降和奖励增长缓慢。QeRL 因而同时解决三个问题：能否用硬件友好的 FP4 权重缩短 rollout；量化噪声是否能促进探索；如何使这种噪声在训练早期有效、后期又不妨碍收敛。 5

总体架构。



其参数化可写为：

$$W_{\text{eff}} = \widehat{W}_{\text{NVFP4}} + \frac{\alpha}{r} BA,$$

其中 $\widehat{W}_{\text{NVFP4}}$ 是冻结的量化基座， A, B 为可训练低秩矩阵， r 为 LoRA rank。论文主要实验使用 $r = 32$ ，因而优化器状态和梯度仅需覆盖约 1% 或更少的参数。 6

QeRL 使用的 NVFP4 解量化形式可抽象为：

$$\widehat{W} = s_{\text{global}} \left(s_{\text{block}} \odot \widehat{W}_{\text{E2M1}} \right),$$

其中 $\widehat{W}_{\text{E2M1}}$ 是 4-bit E2M1 元素；局部尺度通常以 E4M3 FP8 表示，作用于 16 元素微块；全局 FP32 尺度负责覆盖更大的张量动态范围。QeRL 的 H100 路径把这些低比特权重与 BF16 激活送入 Marlin/Triton 类 W4A16 内核。 7

强化学习目标。对同一提示 q 采样 G 个回答 o_i ，组内标准化优势为：

$$\hat{A}_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G) + \epsilon}.$$

策略比值为：

$$\rho_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}.$$

其 GRPO/DAPO 风格目标可简写为：

$$J(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_t \min \left(\rho_{i,t} \hat{A}_i, \text{clip}(\rho_{i,t}, 1 - \epsilon_l, 1 + \epsilon_h) \hat{A}_i \right) - \beta D_{\text{KL}} \right].$$

值得注意的是，虽然通用公式允许 KL 项，QeRL 附录中的主要实验设置没有额外 KL loss，也没有显式 entropy loss；其探索促进主要来自量化和 AQN，而不是给目标函数增加熵奖励。论文使用的 clip 下界、上界分别为 0.2 和 0.28。 ⁸

量化为何可能增强探索。把量化看作参数扰动：

$$\Delta \varepsilon = Q(\theta) - \theta, \quad \pi_{Q(\theta)} / \pi_{\theta} =$$

量化后局部 logits 往往更平坦，策略熵

$$\mathcal{H}(\pi_{\theta}) = -\mathbb{E}_{a \sim \pi_{\theta}} \log \pi_{\theta}(a \mid s)$$

可能上升。QeRL 的分析表明，适度的量化误差能延缓策略过早确定化，使模型在答案空间中探索更多轨迹；但固定噪声在训练后期会成为不可消除的误差地板，因此需要退火。 ⁹

Adaptive Quantization Noise。AQN 在每次 forward 时为指定层或通道重新采样噪声，并随训练阶段指数衰减：

$$\sigma_k = \begin{cases} 0, & k = 0, \\ \sigma_{\text{start}} \left(\frac{\sigma_{\text{end}}}{\sigma_{\text{start}}} \right)^{\frac{k-1}{K-1}}, & 1 \leq k \leq K. \end{cases}$$

主实验使用约 $10^{-2} \rightarrow 5 \times 10^{-4}$ 的退火区间。为避免新增独立参数或破坏融合内核，噪声被合并进 RMSNorm 权重：

$$\text{RMSNorm}_{\text{noise}}(x) = (w + z) \odot \frac{x}{\sqrt{\frac{1}{d} \sum_j x_j^2 + \delta}}, \quad z \sim \mathcal{D}(0, \sigma_k).$$

AQN 作用于与 $W_q, W_k, W_v, W_{\text{gate}}, W_{\text{up}}$ 等投影相关的归一化路径；作者认为其效果近似于对这些矩阵施加逐通道乘性扰动，但不需要修改 GEMM 内核。 ¹⁰

训练伪代码。

输入：

BF16 指令模型 θ_0

校准集 C

RL 提示集 D

LoRA rank r
 每提示采样数 G
 AQN 初末噪声 $\sigma_{\text{start}}, \sigma_{\text{end}}$
 总训练阶段 K

1. 用 C 估计 NVFP4 局部尺度与全局尺度；
2. 将基座权重量化为 NVFP4，并冻结；
3. 在指定 Linear 层挂载 BF16 LoRA 参数 A 、 B ；
4. 对阶段 $k = 0 \dots K$:
 - a. 按指数计划计算 σ_k ；
 - b. 为相关 RMSNorm/通道采样 AQN；
 - c. 对每个提示 q :
 - i. 使用 NVFP4+LoRA actor 生成 G 个回答；
 - ii. 用规则验证器计算奖励 $r_1 \dots r_G$ ；
 - iii. 计算组内标准化优势 $\hat{A}_1 \dots \hat{A}_G$ ；
 - d. 根据 GRPO/DAPO clipped objective 反向传播；
 - e. 只更新 LoRA A 、 B ，不更新 NVFP4 基座；
 - f. 监控 reward、entropy、clip fraction、response length、KL proxy 和量化/未量化 logprob 差；
5. 保存 LoRA adapter、量化配置、尺度和评测结果。

实验设置。

项目	QeRL 设置
基座模型	Qwen2.5-3B/7B/14B/32B-Instruct；并非专门数学预训练模型
RL 数据	GSM8K 训练集约 7,500 题；BigMath 约 122K 样本
每提示生成数	GSM8K 为 8；BigMath 为 16
算法	GSM8K 主要为带多次 policy update 的 GRPO；BigMath 使用更接近 on-policy 的设置及 DAPO 风格 clipping
LoRA	rank 32；主要 Linear 投影层
学习率	QeRL/QLoRA 主要为 10^{-5} ；BF16 LoRA 主要为 5×10^{-6}
优化器	8-bit AdamW
训练 batch	128
最大回答长度	GSM8K 4,096；BigMath 8,192
rollout temperature	1.0
评估采样	temperature 0.6、top-p 0.95、最长 4,096、pass@1
校准	从 OpenThoughts-114k 取 256 条、每条最长 2,048 token
量化	NVFP4/MXFP4 配合 AWQ；H100 上采用 Marlin 类低比特内核
评测集	GSM8K、MATH500、AIME 2024、AIME 2025、AMC 2023
计算资源	rollout/速度实验强调单 H100；最终主要模型结果使用 8 张 H100

上述设置来自论文实验和附录；“单 H100 训练 32B” 应理解为低显存 RL 可行性与特定配置下的运行能力，而非所有结果均由单卡完成。¹¹

GSM8K 关键结果。下表为论文的 pass@1/准确率结果。¹²

模型	方法	权重格式	GSM8K
3B	Base, 无 RL	BF16	61.2
3B	Full FT	BF16	84.4
3B	LoRA	BF16	76.1
3B	QLoRA	NF4	76.1
3B	LoRA	MXFP4	73.4
3B	LoRA	NVFP4	83.3
3B	QeRL: NVFP4 LoRA + AQN	NVFP4	83.7
7B	Base, 无 RL	BF16	76.3
7B	Full FT	BF16	91.2
7B	LoRA	BF16	88.1
7B	QLoRA	NF4	85.0
7B	LoRA	MXFP4	86.4
7B	LoRA	NVFP4	88.5
7B	QeRL: NVFP4 LoRA + AQN	NVFP4	90.8

下图按论文数据重绘，突出 7B 上的主要对比。QeRL 明显超过 BF16 LoRA、QLoRA 和普通 MXFP4 LoRA，但仍略低于 BF16 全参数训练。¹²

QeRL 在 Qwen2.5-7B GSM8K 上的结果对比

BigMath 训练后的多基准结果。表中“平均”是 MATH500、AIME24、AIME25、AMC23 的简单平均。¹³

模型	方法	MATH500	AIME24	AIME25	AMC23	平均
7B	BF16 Full FT	77.4	16.7	10.0	45.0	37.3
7B	BF16 LoRA	77.0	13.3	10.0	42.5	35.7
7B	NVFP4 LoRA	76.8	13.7	10.0	47.5	37.0
7B	NVFP4 LoRA + AQN	77.4	15.5	10.0	42.5	36.4
14B	BF16 Full FT	83.2	20.0	15.1	55.0	43.3
14B	BF16 LoRA	81.0	14.0	13.3	52.5	40.2
14B	NVFP4 LoRA + AQN	80.2	17.5	12.6	57.5	42.0

模型	方法	MATH500	AIME24	AIME25	AMC23	平均
32B	BF16 Full FT	84.0	20.0	23.3	57.5	46.2
32B	BF16 LoRA	83.6	16.7	13.3	55.0	42.2
32B	NVFP4 LoRA + AQN	83.3	16.7	19.2	63.3	45.6

这里有一个重要的审慎解读：AQN 并非在每个子基准上都单调改善。例如 7B 的 NVFP4 LoRA 不加 AQN 时平均为 37.0，而加 AQN 后为 36.4，主要因为 AMC23 从 47.5 降到 42.5；AQN 的价值更多体现在训练速度、早期探索和部分高难度任务，而不能被理解为无条件提高所有评测分数。¹³

效率结果。论文在 7B 实验中报告 BF16 LoRA 基座大小约 15.2GB，NF4 QLoRA 约 5.7GB，NVFP4 QeRL 约 5.9GB。相对 BF16 LoRA，QeRL 的 rollout/训练吞吐随 batch 变化约为 1.5、1.4 和 1.2 倍；QLoRA 则约为 0.8、0.8 和 0.7 倍。论文还概括 QeRL 的训练显存约为 BF16 LoRA 的 40%–50%。这些数字依赖实现、batch、序列长度和 kernel，不能直接等同于理论 4-bit 压缩比。¹⁴

7B 方法	模型载荷	相对速度， batch 2	batch 4	batch 8	解释
BF16 LoRA	15.2GB	1.0×	1.0×	1.0×	基线
NF4 QLoRA	5.7GB	0.8×	0.8×	0.7×	节省显存，但解量化/内核路径拖慢 rollout
NVFP4 QeRL	5.9GB	1.5×	1.4×	1.2×	硬件友好的 packed W4A16 GEMM

消融与分析。

消融维度	观察	工程含义
NVFP4 与 MXFP4	MXFP4 有时早期奖励上升更快，NVFP4 最终成绩通常更稳	早期 reward slope 不能代替最终评测
固定噪声与 AQN	固定噪声后期会限制收敛；指数退火整体最稳定	噪声强度应和训练进度绑定
LoRA rank	16、32、64、128 差异不大，作者选 32	先扩大数据与 rollout batch，而不是盲目增 rank
学习率	较高学习率早期更快，但可能放大量化误差	FP4 RL 需要同时扫描 LR 与噪声，不应独立调参
奖励曲线	QeRL 在 BigMath 上约 200 步进入明显增长，BF16 LoRA 可能超过 500 步	量化噪声对探索阶段最有价值
显式 entropy/KL	主实验未使用额外 entropy/KL loss	QeRL 的提升不能归因于常规熵正则

相关消融和奖励曲线支持“量化噪声可成为探索机制”的观点，但同时也显示其效果依赖任务、模型规模和退火计划。¹⁵

作者结论与局限性。作者认为 NVFP4 与 LoRA 可以同时改善 RL 的系统效率和优化动态，并把低比特误差从纯粹的负面因素重新解释为可控探索噪声。主要局限包括：验证集中于 Qwen2.5 和数学推理；没有覆盖开放式 helpfulness、安全、长对话或人类偏好 RM；缺少充分的多随机种子置信区间；AQN 并非所有子任务都受益；H100 的实现是软件支持的 W4A16，而非 Blackwell 原生 W4A4；量化 actor 与训练策略的 logprob 一致性尚未像后续 QaRL、QUADS 那样被系统处理。 16


可复现与复用要点。

要点	建议
第一复现目标	先复现 Qwen2.5-3B 或 7B、GSM8K、NVFP4A16 + LoRA，不直接上 32B
校准数据	使用 128–256 条与目标 rollout 分布相近的长序列；记录每层 clipping、zero rate 和尺度
Kernel 验证	独立验证量化 GEMM 确实走 Marlin/Triton/CUTLASS 路径，而不是 silent fallback 到 BF16
对照组	BF16 LoRA、NF4 QLoRA、NVFP4 LoRA 无 AQN、NVFP4 LoRA + AQN
日志	reward、pass@1、策略熵、生成长度、重复率、clip fraction、量化/BF16 logprob 差
AQN	从无噪声、固定噪声、线性退火、指数退火四组开始
检查点	LoRA adapter、优化器、量化尺度、随机数状态分别保存
部署	训练结束后同时保留“量化基座 + adapter”和“合并后的 BF16 shadow checkpoint”
版本锁定	CUDA、Triton、vLLM、llm-compressor、Transformers 和 kernel commit 全部固化

官方仓库给出的环境包括 Linux、CUDA 12.4 系列、Triton、llm-compressor，并列出了 H100、B100/B200 和 RTX 5090 等测试或支持路径；具体可用性仍需按 compute capability 和 kernel 后端验证。 17

后训练与强化学习方法栈

“后训练”是基础预训练完成后，为获得指令遵循、领域能力、偏好对齐、推理能力和安全行为而进行的一系列训练。经典 RLHF 流程由监督微调、偏好数据/奖励模型和 PPO 策略优化构成；现代工程中又加入了 LoRA/QLoRA、DPO、GRPO/RLVR、蒸馏、拒绝采样和量化感知训练。InstructGPT 奠定了 SFT→奖励模型→PPO 的典型流程；LoRA 冻结基座只训练低秩增量，QLoRA 进一步把基座存为 4-bit NF4。 18



建议的后训练步骤清单。

阶段	必做工作	主要产物	进入下一阶段的门槛
基座审计	tokenizer、chat template、许可、上下文长度、原始能力基线	可复现基准报告	基准偏差小于预设容忍度

阶段	必做工作	主要产物	进入下一阶段的门槛
数据工程	去重、污染检测、长度分布、难度分层、格式验证	SFT/偏好/RL prompts	无系统性模板错误与答案泄漏
SFT	学习输出风格、任务格式、工具调用和基本推理	SFT checkpoint	held-out loss 与任务指标同步改善
偏好对齐	DPO 或奖励模型训练	preference policy 或 RM	偏好准确率、校准性、无明显长度偏置
在线 RL/RLVR	PPO、GRPO、DAPO 等	强化后 policy	reward 与独立评测同步提升
量化验证	PTQ、QAT、量化 rollout	量化 checkpoint	精度、logprob、吞吐和稳定性达标
安全回归	拒答、越权、事实性、奖励攻击	发布门禁报告	无关键安全回归
部署	kernel、并行、KV cache、batch 调优	服务镜像	p50/p99、吞吐和单位成本达标

常见方法比较。

方法	是否更新权重	训练数据	优点	主要代价与风险	与低比特的关系
PTQ	否或仅优化少量尺度	小型校准集，可无标签	成本最低、快速部署	W4A4 对激活离群值和校准分布敏感	NVFP4/MXFP4/MXFP8 最直入口
QAT	是；forward 模拟量化	原训练或代表性数据	可适应量化网格，通常优于 naïve PTQ	训练成本高；fake quant 与真实 kernel 可能不一致	FP4 端到端训练和 rollout 对齐的重要手段
SFT	全量或 PEFT	prompt-response	稳定、易调试，是 RL 前置条件	容易过拟合格式；不能直接优化偏好或可验证奖励	可用 BF16、FP8、LoRA、QLoRA
PEFT	更新少量参数	与具体任务相同	降显存、便于多任务 adapter	能力上限有时低于全参数微调	LoRA、IA3、Prefix 等的总称
LoRA	更新低秩矩阵	SFT、偏好或 RL 数据	优化器状态小，可独立保存 adapter	rank/target modules 不当会欠拟合	可配 BF16、FP8、NVFP4/MXFP4 基座
QLoRA	LoRA；基座 NF4	多用于 SFT，也可用于 RL	单卡可微调大模型	NF4 未必有高吞吐原生 GEMM；RL rollout 可能变慢	低显存强，但不等于硬件原生 FP4
DPO	更新 policy	chosen/rejected 对	无需在线 rollout 和显式 RM，流程简单	受偏好数据质量、reference 与 β 敏感	适合先用 LoRA/QLoRA 验证低比特

方法	是否更新权重	训练数据	优点	主要代价与风险	与低比特的关系
奖励模型	更新分类/打分模型	偏好排序	能为开放式回答提供稠密信号	长度、风格和分布外偏差会被 policy 利用	RM 本身也可 FP8/INT8，但需谨慎校准
PPO-RLHF	policy 与 value head	在线 rollout + RM	成熟、可控制 KL	actor、reference、RM、critic 显存与通信重	低比特 rollout 收益大，错配风险也大
GRPO/RLVR	policy；通常无独立 critic	可验证奖励 prompts	比 PPO 少 value model，适合数学/代码	稀疏奖励、组内方差和答案解析敏感	QeRL、QaRL、QUADS 的主要场景
蒸馏/拒绝采样	SFT 更新	teacher 生成轨迹	稳定，易大规模生成	继承 teacher 偏差，缺少在线探索	可先用低比特 teacher rollout 降生成成本

DPO 将偏好优化写成相对 reference policy 的分类式目标，省去显式奖励模型和在线 RL；PPO 则通过 clipped surrogate objective 限制策略步长；GRPO 用同一提示的多回答相对奖励估计优势，省去独立 value model。

19

常用超参数起点。以下范围是工程初始扫描区间，不是跨模型通用最优值。Hugging Face TRL 文档当前建议 adapter SFT 可从约 10^{-4} 学习率开始，adapter DPO 可从约 10^{-5} 开始；PPO 默认示例包括 4 个 PPO epoch、KL 系数 0.05、clip 0.2、GAE $\lambda = 0.95$ 和梯度裁剪 1.0。

20

方法	建议起始范围	优先扫描项
全参数 SFT	LR 5×10^{-6} – 2×10^{-5} ；warmup 1%–5%；weight decay 0–0.1	LR、有效 token batch、epoch
LoRA SFT	LR 5×10^{-5} – 2×10^{-4} ；rank 8–64；alpha 取 r 或 $2r$ ；dropout 0–0.1	target modules、rank、LR
QLoRA SFT	LR 10^{-4} – 3×10^{-4} ；NF4；double quant；BF16 compute	sequence packing、paged optimizer、rank
DPO LoRA	LR 5×10^{-6} – 3×10^{-5} ； β 0.05–0.5	β 、长度归一化、reference
PPO	policy LR 5×10^{-7} – 5×10^{-6} ；clip 0.1–0.2；KL target 0.02–0.1	KL 系数、rollout batch、PPO epochs
GRPO/RLVR	adapter LR 5×10^{-6} – 5×10^{-5} ；每提示 4–16 条；clip 0.2 左右	group size、reward variance、生成长度
QeRL 式 FP4 RL	LoRA rank 16–64；LR 5×10^{-6} – 3×10^{-5} ；AQN $10^{-2} \rightarrow 10^{-4}$ 量级	LR $\times$ 噪声二维扫描、actor/trainer logprob 差
QAT	先 warm-start；量化逐层开启；末段降 LR 2–10 倍	fake quant 位置、STE、敏感层回退

常见陷阱与调参建议。

现象	常见原因	建议诊断与修复
reward 上升但真实任务下降	reward hacking、长度偏置、答案解析漏洞	同步记录独立 verifier、长度分桶、人工抽检
策略熵快速归零	LR 太高、奖励过稀、FP4 grid 过粗	降 LR、扩大 group、AQN/熵正则、混合精度敏感层
量化 rollout 生成乱码或重复	激活量化、logprob 错配、路由漂移	先退到 W4A16；比较 BF16 与量化 token logprob
PPO KL 爆炸	多 epoch、clip 太松、actor/reference 精度不一致	减少 update epoch、提高 KL penalty、统一 forward 精度
DPO 输出越来越长	偏好数据存在长度偏置	长度匹配采样、加 held-out win rate、监控 token-normalized loss
QLoRA 显存仍超限	长序列激活和 KV 占主导	gradient checkpoint、packing、FlashAttention、减 microbatch
FP4 理论快但实测慢	kernel fallback、形状未对齐、反量化开销	profiler 检查算子；使 K 维满足 16/32 对齐；固定 kernel 版本
多卡低比特反而通信变慢	尺度同步、all-gather 重量化、碎片化小 kernel	先测单卡算子，再测并行；合并尺度通信；增加计算粒度
小模型 FP4 掉点大	冗余更少、离群值占比更高	保留 embedding、lm_head、down_proj 或路由器为高精度
rollout 与 trainer 不一致	actor 是量化模型，trainer 用 BF16 或另一套尺度	rollout-aligned QAT、shadow forward、importance-ratio clipping

计算、显存和吞吐权衡。在 SFT 中，权重只是显存的一部分，激活、梯度和 Adam 状态常占更大比例，因此把冻结基座从 BF16 降到 4-bit 对 LoRA 很有效，对全参数 Adam 训练的收益却可能被 BF16/FP32 master weights 和优化器状态抵消。在 RL 中，rollout 经常消耗大部分 wall time，低比特 GEMM 的收益比纯 SFT 更明显；但长 context 下 KV cache、采样和通信可能成为新瓶颈。PPO 还需 policy、reference、reward model 和 value model，GRPO/RLVR 因省去 critic，通常更适合作为低比特 RL 的第一验证场景。²¹

近一年研究与产业趋势

检索窗口为 2025 年 8 月 2 日至 2026 年 8 月 2 日。该期间最显著的趋势是：**FP4 研究从静态 PTQ 扩展到 rollout、trainer、KV cache、MoE router 和全训练链路；研究问题从张量 MSE 转向策略分布误差。**

QeRL: Beyond Efficiency — Quantization-enhanced Reinforcement Learning for LLMs. arXiv: 2510.11696。该工作使用 NVFP4 冻结权重、BF16 LoRA 和 AQN，在 Qwen2.5 3B–32B 上进行 GRPO/DAPO 数学推理后训练。它直接在 RL 中验证 NVFP4，7B GSM8K 达到 90.8%，MATH500 达到 77.4%，并报告超过 1.5 倍的特定 rollout 加速。其最大贡献是把量化误差解释为可调探索噪声；局限是主要为 W4A16、数学任务和单一模型家族。²²

QaRL: Rollout-Aligned Quantization-Aware RL for Fast and Stable Training under Training-Inference Mismatch. arXiv:2604.07853。QaRL 研究 W4A16 rollout 与高精度 trainer 的 forward mismatch，引入 rollout-aligned QAT 和 TBPO 双边 clipping，对异常 token 的 policy ratio 更保守。它在 Qwen2.5-Math、Qwen3-8B 和 Qwen3-30B-A3B MoE 上验证 GRPO/GSPO 类 RL；30B-A3B 平均数学分数为 51.2，接近 BF16

的 52.1, 显著高于 naïve 量化 rollout 的 45.7, 同时相对 BF16 约 1.3 倍加速。格式是通用 W4A16, 而不是专门绑定 NVFP4。 23

QuRL: Efficient Reinforcement Learning with Quantized Rollout. arXiv:2602.13953, ICLR 2026.

QuRL 使用 INT8 和 FP8 actor 加速 DeepScaleR/DAPO rollout, 并指出 RL 参数更新很小, 容易被量化噪声淹没。其 Adaptive Clipping Ratio 根据全精度和量化 actor 的比值动态限制更新, Invariant Scaling 则放大有效更新相对于量化步长的可见度。论文报告 rollout 提速 20%–80%。它不是 FP4 工作, 但建立了后续 FP4 RL 的关键原则: 必须显式建模 quantized actor 与训练 policy 的分布差异。 24

Decomposing MXFP4 Quantization Error for LLM Reinforcement Learning. arXiv:2605.20402. 该工作把 MXFP4 RL 误差分为尺度偏置、deadzone 截断和不可约网格噪声, 并分别使用 Macro-block Scaling、Outlier Fallback 和 AQN。它直接验证 MXFP4 W4A4 RL: Qwen2.5-3B 在 GSM8K 上从 naïve MXFP4 的 60.1% 恢复到 81.3%, 距 BF16 82.0% 仅 0.7 个百分点; Qwen3-30B-A3B MoE 恢复至距 BF16 3.0 个百分点。它的重要结论是, FP4 误差不能只靠单一旋转或单一尺度优化解决。 25

QUADS: Stabilizing NVFP4 Reinforcement Learning for MoE via Quantization-error Alignment across Dual Sides. arXiv:2607.15810. QUADS 针对 Blackwell 原生 NVFP4 W4A4 MoE RL, 发现 naïve NVFP4 rollout 加 BF16 trainer 会因激活量化和 logprob mismatch 在约百余步后坍塌。它采用非对称 W4A16 QAT trainer 对齐权重路径, 并在 rollout 端进行 Residual Activation Compensation, 同时保留原生 W4A4 GEMM。最终达到 BF16 级准确率, 相对 naïve NVFP4 平均 pass@1 提升 21.49 点, rollout 吞吐仍比 FP8 高约 16%。这是目前原生 NVFP4 RL 工程价值最高的结果之一。 26

HiFloat4 Format for End-to-End Reinforcement Learning Post-Training of LLMs. arXiv:2607.26515. 该研究提出 HiFloat4, 并与 MXFP4 系统比较 trainer 和 rollout 精度组合。在 Qwen2.5-3B、GSM8K GRPO 上, BF16/BF16 为 86.96%; FP4 trainer 加 BF16 rollout 仍达 HiF4 86.88%、MXFP4 86.20%; 但 BF16 trainer 加 FP4 rollout 降至 HiF4 78.01%、MXFP4 50.57%。端到端 FP4 分别为 82.03% 和 73.31%。结果强烈说明: rollout 激活量化比 trainer 侧 fake quant 更容易破坏 RL, BF16 trainer 并不能自动纠正低比特 actor。 27

ScaleSweep: Accurate NVFP4 Post-Training Quantization of LLMs via Block Scale Initialization.

arXiv:2606.07618. ScaleSweep 面向 NVFP4 PTQ 的两级尺度结构, 在 FP8 bit-pattern 空间内搜索局部尺度, 并为 MSE/W MSE 最优尺度推导紧凑搜索边界。工作覆盖 Llama、Qwen, 以及权重激活、KV cache 和 query state 的渐进量化; 在最激进的 WAKVQ 设置下仍恢复约 93%–95% 的 BF16 综合性能, 并声称相对默认 NVFP4 算子几乎无额外运行时开销。该方法尚未直接验证 RL, 但适合生成量化 rollout actor 的初始 checkpoint。 28

Benchmarking Post-Training Quantization under Microscaling Floating Point Formats. arXiv:

2601.09555. 华为研究团队系统评估 7 种以上 PTQ 方法、15 个基准和多个 LLM/VLM 家族。结论是 MXFP8 在 W8A8 场景通常接近无损, 而 MXFP4 W4A4 风险显著; 算法与格式的兼容性比算法在 INT4 上的声誉更重要, 部分全局旋转会破坏 MX 微块结构, 仿射变换和误差补偿更稳健; 语言模型主体比视觉编码器更敏感。该工作属于 PTQ, 不含 RL, 但为选择 MXFP8 作为低风险默认格式提供了强证据。 29

DuQuant++: Fine-grained Rotation Enhances Microscaling FP4 Quantization. arXiv:2604.17789.

DuQuant++ 把数据感知旋转块大小与 MXFP4 的 32 元素 microscaling group 对齐, 仅需一次局部旋转, 而不再使用原 DuQuant 的双旋转和 zigzag permutation, 从而减少在线旋转成本。Llama3-8B MXFP4 W4A4 下, 配合 GPTQ 的 WikiText2 perplexity 为 6.88, FP16 为 6.14, 平均零样本准确率 67.1%; 比 MR-GPTQ 改善 0.41 perplexity 和约 1 个百分点。它是 PTQ 工作, 没有直接 RL 验证, 但对缓解 MXFP4 activation outlier 很有参考价值。 30

TorchAO/TorchTitan 的 MXFP8 千卡实践。2025 年 9 月，PyTorch 团队公开了 Llama3-70B 在 Crusoe B200 集群上的 MXFP8 实验，规模最高 1,856 张 GPU，报告相对 BF16 约 1.22–1.28 倍训练加速及近似等价的 loss 收敛。TorchAO 文档同时显示，MXFP8 端到端训练已进入可用原型阶段，而 NVFP4 训练性能和 MXFP4 训练支持仍较不成熟。这是产业界把 MXFP8 作为 Blackwell 低风险训练格式的重要信号，但该实践主要是预训练而非 RL。³¹

AMD Quark 与 MI355 的 MXFP4 实践。AMD Quark 支持 MXFP4、MXFP6 和混合精度，并整合 GPTQ、SmoothQuant、QuaRot 和 AutoSmoothQuant，量化模型可部署到 MI355，并与 vLLM、SGLang 集成。AMD 报告 DeepSeek-R1-0528 的 MXFP4 在 AIME24、GPQA Diamond 和 MATH500 等任务保留超过 99.5% 的基准表现，同时指出较小模型上的损失更明显，MXFP6 或 MXFP4/MXFP6 混合精度通常更稳。这是 MXFP4 跨厂商生态相对 NVFP4 的主要优势。³²

格式比较。

维度	NVFP4	MXFP8	MXFP4
元素格式	E2M1, 4 bit	常用 E4M3，也可 E5M2, 8 bit	E2M1, 4 bit
微块大小	通常 16 元素；权重训练可用 16×16 二维尺度	32 元素	32 元素
局部尺度	FP8 E4M3	E8M0，二次幂	E8M0，二次幂
全局尺度	有 FP32 tensor-level scale	通常无额外全局尺度	通常无额外全局尺度
理论权重载荷	约 4.5 bit/param，不计对齐	约 8.25 bit/param	约 4.25 bit/param
精度	通常为三者中最好的 FP4；对尺度实现仍敏感	最稳，常接近 BF16/FP8	三者中最易受 outlier 和 deadzone 影响
速度潜力	Blackwell 原生 W4A4 潜力最高	Blackwell/MI350 上稳定的训练加速	原生 W4A4 潜力高，但补偿算法可能增加开销
NVIDIA	原生要求 SM100+；H100 多为 W4A16 软件路径	Blackwell 原生	Blackwell 原生
AMD	非标准主路径	MI350/MI355 支持 MX 生态	MI350/MI355 原生支持
可移植性	NVIDIA 专有	OCP 开放格式，跨厂商	OCP 开放格式，跨厂商
实现复杂度	高：两级尺度、全局 amax 同步、重排、swizzle	中：需要双方向量化与 block alignment	中高：格式简单，但精度恢复复杂
最适合	Blackwell 极限显存/rollout；有 QAT 与对齐能力的团队	生产训练、首次低精度 RL、跨平台稳健方案	跨 NVIDIA/AMD 推理；大模型 PTQ；可容忍混合精度补偿
不适合	旧 GPU 上期待原生 W4A4；无校准与监控	要求接近 4-bit 极限压缩	小模型 naïve W4A4 RL、激活离群值严重的模型

NVIDIA Transformer Engine 明确区分了 H100 的 FP8 支持与 Blackwell 新增的 NVFP4/MXFP8 支持；NVFP4 的 FP8 局部尺度、全局 FP32 尺度、2D 权重量化、随机舍入和 RHT 都增加了训练实现复杂度。OCP MX 格式的 32 元素 E8M0 block scale 则带来更好的跨厂商一致性。³³

下图基于格式位宽和块尺度开销给出理论权重载荷。它不包含 padding、embedding、lm_head、量化元数据、LoRA、优化器、激活和 KV cache；实际 checkpoint 通常更大。TorchAO 的 Llama3.1-8B 示例中，BF16、MXFP8、NVFP4 checkpoint 分别约为 16.1GB、9.32GB 和 6.05GB，说明实现载荷与理论值之间存在明显差异。³⁴

不同低比特格式的理论权重存储量

产业主流选择及原因。

生态	当前主要选择	原因
NVIDIA Hopper	FP8 W8A8；W4A16/INT4/NVFP4A16 用于省权重显存	H100 原生 Tensor Core 主路径是 FP8；全 NVFP4 W4A4 不是 Hopper 原生路径
NVIDIA Blackwell	MXFP8 用于稳健训练；NVFP4 用于最高压缩；MXFP4 用于 OCP 兼容	三者都有硬件/软件投入，但成熟度不同
PyTorch/TorchAO	MXFP8 训练优先；NVFP4 QAT/推理推进中	MXFP8 已有大规模收敛和加速数据，FP4 训练尚需补齐 kernel 与数值策略
vLLM/LLM Compressor	NVFP4、MXFP4、MXFP8、FP8、W4A16	覆盖 PTQ、AWQ、GPTQ 与 compressed-tensors 部署
NVIDIA TensorRT-LLM	FP8/NVFP4 checkpoint 与 Blackwell 推理	深度绑定 Tensor Core 和 Model Optimizer
AMD ROCm/Quark	MXFP4、MXFP6、MX 混合精度	OCP 标准、MI355 原生 MFMA scale 指令、跨 vLLM/SGLang
大模型 RL 研究	先 W4A16 或 FP8 rollout，再探索 W4A4	trainer/actor 错配和激活量化仍是主要稳定性障碍

LLM Compressor 的硬件指南推荐 Blackwell 使用 NVFP4/MXFP4 获得最高压缩，MXFP8/FP8 获得更平衡的精度和速度；对 Hopper 则推荐 FP8 或 W4AFP8，而不是原生 NVFP4 W4A4。其 NVFP4 还需要全局尺度和部分 fused-weight reindexing，MXFP4/MXFP8 则更容易进行无数据 checkpoint 转换。³⁵

尚未解决的挑战。

挑战	本质	值得研究的方向
Trainer-rollout mismatch	优势和 importance ratio 由不同数值策略产生	双 actor shadow forward、量化一致性约束、误差感知 clipping
激活离群值	单个 outlier 抬高共享尺度，普通值落入 deadzone	局部旋转、残差补偿、稀疏高精度 fallback
微小 RL 更新不可见	参数更新小于 FP4 网格间隔	error feedback、stochastic rounding、update scaling
MoE router 漂移	轻微 logit 误差改变 expert 选择	router 保留高精度、expert routing consistency loss
KV cache 与 query state	长上下文下 KV 占主导，误差会累积	分层 KV 精度、token/头敏感量化、在线尺度

挑战	本质	值得研究的方向
多卡尺度同步	全局 amax 和布局转换增加通信	局部尺度、异步统计、量化 collectives
Fake quant 与真 kernel 差异	模拟舍入、padding 和算子顺序不完全一致	kernel-in-the-loop QAT、bit-exact 仿真
评估不足	数学 pass@1 不能代表对话、安全和校准	多任务、长上下文、安全、置信度和跨 seed 评测
生态格式碎片化	NVFP4 专有、MX 开放但实现细节可不一致	标准 checkpoint、conformance tests、跨厂商 bit-exact 验证
端到端成本模型	理论 FLOPS 不等于 RL wall time	同时建模生成长度、KV、通信、reward latency 与利用率

工程落地方案

推荐采用“**BF16 基线** → **MXFP8/FP8** → **W4A16** → **原生 W4A4**”四级路线。每一级都必须有独立质量门禁，不能因为量化 MSE 较小就直接进入 RL。

分步实施方案。

阶段	实施内容	退出条件
基线固化	固定数据、模板、随机种子、评测器；训练 BF16 LoRA/SFT 和 BF16 RL 基线	三次重复运行方差可接受；所有指标可复现
Kernel 探针	对目标 GPU 测 BF16、FP8/MXFP8、W4A16、W4A4 GEMM；检查实际算子和 fallback	目标形状真实加速，而非微基准虚高
PTQ 验证	对最终 SFT checkpoint 做 NVFP4/MXFP4/MXFP8 PTQ；比较 RTN、AWQ、GPTQ	静态任务和 token-level KL 达标
W4A16 PEFT	冻结低比特权重，BF16 LoRA；先 SFT/DPO，再 GRPO	稳定性不低于 BF16 LoRA；吞吐有正收益
量化 rollout	trainer 保持 BF16/FP8，actor 使用低比特；同时运行 shadow logprob	actor/trainer KL、ratio tail、乱码率受控
噪声与对齐	加 AQN、QAT、TBPO/动态 clipping 或残差补偿	reward 与独立任务同时提高
原生 W4A4	仅在 B200/GB200 或 MI355 等原生硬件上开启激活量化	无策略坍缩，吞吐收益覆盖补偿开销
混合精度收敛	将 router、lm_head、embedding、down_proj 或异常层恢复 MXFP8/BF16	达到质量 SLA 的最小高精度集合
生产灰度	离线回放、影子流量、小流量 A/B、逐步扩容	p99、质量、安全和成本均达标

工具链建议。

层级	NVIDIA 路线	AMD/跨平台路线
训练框架	PyTorch、Transformers、TRL、PEFT、Accelerate	PyTorch、Transformers、TRL、PEFT
分布式	FSDP2/TorchTitan、DeepSpeed ZeRO、Megatron-Core	FSDP、DeepSpeed、Megatron/ROCm
低精度训练	Transformer Engine、TorchAO MXFP8/NVFP4	TorchAO MX、ROCm low precision
PTQ/QAT	NVIDIA Model Optimizer、LLM Compressor、TorchAO QAT	AMD Quark、TorchAO、GPTQ/SmoothQuant
RL	TRL、verl、OpenRLHF、NeMo-RL、自研 GRPO	verl、OpenRLHF、TRL、自研
Rollout	vLLM、SGLang、TensorRT-LLM	vLLM、SGLang
Kernel	CUTLASS、Marlin、Triton、cuBLASLt	hipBLASLt、Composable Kernel、Triton/ROCm
性能分析	Nsight Systems/Compute、PyTorch Profiler	rocprof、Omniperf、PyTorch Profiler
实验跟踪	W&B、MLflow、自建指标仓库	同左

Transformer Engine 的原生 NVFP4 训练要求 SM100 或更新架构；TorchAO 当前把 MXFP8 端到端训练列为较成熟原型，而 NVFP4/MXFP4 的训练性能仍在优化。LLM Compressor 能生成 NVFP4、MXFP4、MXFP8 checkpoint 并交给 vLLM，但必须确认目标硬件是否真正执行激活量化。 ³⁶

推荐实验矩阵。

实验组	Trainer	Rollout	基座	Adapter/QAT	目的
A	BF16	BF16	BF16	LoRA	质量与稳定性基线
B	BF16	BF16	NF4	LoRA	QLoRA 显存基线
C	BF16	W4A16	NVFP4	LoRA	QeRL 核心效率验证
D	BF16	W4A16	MXFP4	LoRA	格式对比
E	BF16	W4A16	NVFP4	LoRA + AQN	探索噪声消融
F	MXFP8	MXFP8	MXFP8	LoRA 或全参数	低风险低精度基线
G	W4A16 QAT	NVFP4 W4A4	NVFP4	QAT + 残差补偿	QUADS 式原生 FP4
H	W4A16 QAT	MXFP4 W4A4	MXFP4	MBS/OF/AQN	MXFP4 全链路验证
I	BF16	NVFP4/MXFP4 W4A4	混合精度	无对齐	故障对照，不用于生产

每组至少做 3 个随机种子；将训练步数、prompt、每 prompt 生成数、token budget 和 reward evaluator 固定。吞吐比较应同时报告 tokens/s、samples/s、每 RL step 时间、GPU-hours 和平均生成长度，避免因低比特模型生成更短文本而出现虚假加速。

评估指标。

维度	必测指标
任务质量	pass@1、pass@k、exact match、代码单测通过率、偏好 win rate
RL 优化	mean/std reward、零奖励比例、优势方差、clip fraction、approx KL
策略分布	BF16/量化 token KL、top-1 token 一致率、importance ratio p95/p99/max
探索	token entropy、回答多样性、distinct-n、self-BLEU、轨迹唯一率
稳定性	NaN/Inf、乱码率、重复循环、EOS 缺失率、reward collapse
量化误差	每层 NMSE、zero/deadzone rate、saturation rate、scale 分布
MoE	router top-k 一致率、expert load balance、路由熵
性能	prefill/decode tokens/s、rollout samples/s、step time、MFU
显存	idle、rollout peak、backward peak、KV cache、优化器与碎片
服务	p50/p95/p99 延迟、最大并发、单位百万 token 成本
安全	越权、拒答、事实性、奖励攻击、提示注入和工具误用

尤其需要加入：

$$D_{\text{actor-trainer}} = \mathbb{E}_t [D_{\text{KL}}(\pi_{\text{quant}}(\cdot | s_t) \parallel \pi_{\text{train}}(\cdot | s_t))],$$

以及 ratio tail：

$$P(|\log \rho_t| > \tau).$$

对 RL 来说，这两个指标往往比普通权重 MSE 更能提前预警训练坍缩。QaRL、QuRL、QUADS 和 HiFloat4 的结果均支持这一判断。²

风险与回滚策略。

风险	触发阈值示例	自动降级	完整回滚
reward collapse	连续若干窗口下降超过 20%	关闭 AQN、降低 LR、回到上一个 adapter	恢复 BF16 actor 与 checkpoint
actor/trainer KL 过高	p99 ratio 或 KL 超门槛	W4A4→W4A16；减小 PPO/GRPO clip	BF16/FP8 rollout
乱码/重复	比基线增加超过 2-3 倍	激活恢复 MXFP8/BF16	禁用量化 rollout
任务掉点	核心指标下降超过 SLA	敏感层高精度；换 GPTQ/AWQ	BF16 或 MXFP8 checkpoint
性能无收益	加速低于 10% 或成本更高	去除补偿 kernel；调整 batch/shape	保留低比特仅用于存储
MoE 路由漂移	router top-k 一致率过低	router/gate 保留 BF16	整个 MoE block 提升精度

风险	触发阈值示例	自动降级	完整回滚
多卡不稳定	amax 不一致、通信超时	关闭量化 all-gather	恢复 BF16 collectives
软件兼容问题	kernel fallback、版本回归	固定已验证镜像	使用上一生产镜像

回滚资产必须包括：原始 BF16 基座、SFT checkpoint、每阶段 LoRA adapter、量化前 checkpoint、量化尺度与 recipe、优化器状态、随机数状态、容器镜像和完整评测输出。不要只保存已经合并和压缩后的单一模型文件。

预期收益估算。

以下为规划区间而非保证值。QeRL 的 H100 W4A16 数据、PyTorch 的 B200 MXFP8 数据、TorchAO 的 B200 NVFP4 inference 数据和 QUADS 的 FP8 对比可作为参考；实际结果高度依赖序列长度、batch、模型结构、KV cache 和 kernel。 37

方案	典型硬件	权重显存相对 BF16	训练/rollout 吞吐目标	精度风险	工程成本	推荐度
BF16 LoRA	A100/ H100/ B200	100%	1.0×	最低	低	必须保留的基线
NF4 QLoRA	A100/ H100	约 25%–40% checkpoint	RL 中可能 0.7–1.0×	低到中	低	SFT 强，RL 不一定快
FP8 W8A8	H100/ B200	约 50%–60%	1.1–1.4×	低	中	Hopper 首选
MXFP8	B200/ MI350+	理论约 51.6%	1.15–1.3×	低	中	新项目低风险首选
NVFP4A16 + LoRA	H100/ B200	理论权重约 28%，实际更高	QeRL 类 1.2–1.5×	中	中	H100 RL 推荐
MXFP4A16 + LoRA	H100/ B200/ MI355	理论权重约 26.6%	1.1–1.5×，需实测	中到高	中	跨平台验证方案
NVFP4 W4A4	B200/ GB200	理论约 28%	prefill 潜力 1.5–1.8×；对 FP8 rollout 可约 1.16×	高	高	有 QAT/对齐能力时采用
MXFP4 W4A4	B200/ MI355	理论约 26.6%	理论高，补偿后视 workload	很高，尤其小模型 RL	很高	大模型推理优先，RL 谨慎
FP4/MXFP8 混合	B200/ MI355	约 30%–50%	1.2–1.6×	中	高	生产最现实的极限方案

以仅权重理论载荷计算：

模型规模	BF16	MXFP8	NVFP4	MXFP4
7B	14.0GB	7.2GB	3.9GB	3.7GB
14B	28.0GB	14.4GB	7.9GB	7.4GB
32B	64.0GB	33.0GB	18.0GB	17.0GB
70B	140.0GB	72.2GB	39.4GB	37.2GB

这些值只用于容量规划。真实训练显存还包括 LoRA、激活、临时反量化 buffer、KV cache、CUDA graph、通信 buffer 和内存碎片；全参数 QAT 还可能保留 BF16 master weights，因此不会获得同等比例的总显存下降。

结论与决策建议

对于 **A100/H100 上的 7B–70B 后训练**，优先选择 BF16/FP8 训练基线，加 NVFP4A16 或 MXFP4A16 冻结基座和 BF16 LoRA。若任务是数学、代码或其他可验证奖励，QeRL 的 NVFP4 + LoRA + AQN 是最值得首先复现的方案；但必须额外加入量化 actor 与 BF16 trainer 的 token-level KL 和 importance-ratio tail 监控。H100 上不应把 NVFP4A16 的软件 kernel 支持误认为原生 W4A4 Tensor Core 训练。³⁸

对于 **B200/GB200 上的新系统**，建议先用 MXFP8 建立稳定、可扩展的训练与 RL 基线。MXFP8 的压缩率低于 FP4，但已有大规模等价收敛数据，开发和调试成本显著更低。只有在 rollout 已成为明确瓶颈、质量门禁完善后，才应迁移到 NVFP4 W4A4，并采用 rollout-aligned QAT、残差激活补偿、敏感层高精度回退或 QUADS 类双端对齐。³⁹

对于 **AMD MI350/MI355 或跨厂商部署**，MXFP8/MXFP4 比 NVFP4 更适合作为 checkpoint 标准。MXFP4 应配合 GPTQ、AutoSmoothQuant、局部旋转、MXFP6 混合精度或异常通道回退；小于约 30B 的模型和端到端 RL 不宜从 naïve W4A4 起步。⁴⁰

从研究角度看，未来最有价值的方向不是继续单独降低静态量化 MSE，而是建立 **策略级量化理论与系统**：联合优化 trainer、rollout、reference、reward model 和 KV cache 的精度；使量化误差与 trust region、KL、优势估计和探索调度协同；发展对 MoE router、长上下文和工具调用轨迹敏感的混合精度；并建立跨 NVIDIA/AMD 的 bit-exact checkpoint 与一致性测试。

最终的工程决策可压缩为三条：

优先级	决策
质量优先	MXFP8/FP8；低比特仅用于冻结基座或 rollout，保留 BF16 shadow path
成本与质量平衡	NVFP4A16/MXFP4A16 + LoRA/GRPO；加入 QeRL 式噪声和错配监控
极限吞吐与显存	Blackwell NVFP4 W4A4 或 MI355 MXFP4 W4A4；必须使用 QAT、残差补偿和混合精度回退

低比特 RL 的关键不再是“4 bit 是否足够表示权重”，而是“**rollout 所采样的策略，是否仍然是 trainer 以为自己在优化的那个策略**”。QeRL 展示了量化噪声可能带来的探索收益，而 QaRL、QuRL、QUADS 和 HiFloat4 则共同给出了边界条件：只有当量化误差被对齐、监控和退火时，FP4 才能从压缩手段升级为可靠的后训练计算范式。

-
- 1 4 22 <https://arxiv.org/abs/2510.11696>
<https://arxiv.org/abs/2510.11696>
- 2 23 <https://arxiv.org/html/2604.07853v1>
<https://arxiv.org/html/2604.07853v1>
- 3 33 https://docs.nvidia.com/deeplearning/transformer-engine/user-guide/examples/fp8_primer.html
https://docs.nvidia.com/deeplearning/transformer-engine/user-guide/examples/fp8_primer.html
- 5 9 13 <https://arxiv.org/pdf/2510.11696>
<https://arxiv.org/pdf/2510.11696>
- 6 7 8 10 11 12 14 15 16 37 <https://arxiv.org/html/2510.11696v1>
<https://arxiv.org/html/2510.11696v1>
- 17 38 <https://github.com/NVlabs/QeRL>
<https://github.com/NVlabs/QeRL>
- 18 <https://arxiv.org/abs/2106.09685>
<https://arxiv.org/abs/2106.09685>
- 19 <https://arxiv.org/abs/1707.06347>
<https://arxiv.org/abs/1707.06347>
- 20 https://huggingface.co/docs/trl/sft_trainer
https://huggingface.co/docs/trl/sft_trainer
- 21 https://huggingface.co/docs/trl/ppo_trainer
https://huggingface.co/docs/trl/ppo_trainer
- 24 <https://arxiv.org/abs/2602.13953>
<https://arxiv.org/abs/2602.13953>
- 25 <https://arxiv.org/html/2605.20402v1>
<https://arxiv.org/html/2605.20402v1>
- 26 <https://arxiv.org/html/2607.15810v1>
<https://arxiv.org/html/2607.15810v1>
- 27 <https://arxiv.org/html/2607.26515v1>
<https://arxiv.org/html/2607.26515v1>
- 28 <https://arxiv.org/pdf/2606.07618>
<https://arxiv.org/pdf/2606.07618>
- 29 <https://arxiv.org/html/2601.09555v1>
<https://arxiv.org/html/2601.09555v1>
- 30 <https://arxiv.org/html/2604.17789v1>
<https://arxiv.org/html/2604.17789v1>
- 31 39 <https://pytorch.org/blog/accelerating-2k-scale-pre-training-up-to-1-28x-with-torchao-mx8-and-torchtitan-on-crusoe-b200-cluster/>
<https://pytorch.org/blog/accelerating-2k-scale-pre-training-up-to-1-28x-with-torchao-mx8-and-torchtitan-on-crusoe-b200-cluster/>

32 40 <https://rocm.blogs.amd.com/software-tools-optimization/mxfp4-mxfp6-quantization/README.html>

<https://rocm.blogs.amd.com/software-tools-optimization/mxfp4-mxfp6-quantization/README.html>

34 <https://docs.pytorch.org/ao/stable/workflows/inference.html>

<https://docs.pytorch.org/ao/stable/workflows/inference.html>

35 <https://docs.vllm.ai/projects/llm-compressor/en/latest/steps/choosing-scheme/>

<https://docs.vllm.ai/projects/llm-compressor/en/latest/steps/choosing-scheme/>

36 https://docs.nvidia.com/deeplearning/transformer-engine-releases/release-2.14/user-guide/features/low_precision_training/nvfp4/nvfp4.html

https://docs.nvidia.com/deeplearning/transformer-engine-releases/release-2.14/user-guide/features/low_precision_training/nvfp4/nvfp4.html